

UNIVERSIDAD NACIONAL DEL ALTIPLANO
FACULTAD DE INGENIERÍA ESTADÍSTICA E INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA ESTADÍSTICA E
INFORMÁTICA



ANÁLISIS DISCRIMINANTE (Lineal y Cuadrático)

Aplicado a la predicción de aprobación de estudiantes
a partir de horas de estudio y nota previa

Docente: Ing. Eloy Carpio Vargas

Presentado por: Quispe Holguin Alexander

Curso: Aprendizaje Supervisado

Semestre: VII – 2026-I

Puno – Perú
2026

Índice general

Índice general	1
Índice de figuras	3
Índice de cuadros	4
1. Introducción	5
1.1. Objetivos	5
1.1.1. Objetivo general	5
1.1.2. Objetivos específicos	5
2. Marco Teórico	7
2.1. Análisis Discriminante Lineal (LDA)	7
2.2. Análisis Discriminante Cuadrático (QDA)	7
2.3. LDA vs QDA: ¿Cuándo usar cada uno?	8
2.4. Métricas de evaluación	8
3. Datos y Metodología	9
3.1. Descripción del dataset	9
3.2. Exploración gráfica	9
3.3. Prueba de normalidad	11
3.4. Partición de los datos	11
4. Implementación en RStudio	12
4.1. Código R	12
5. Implementación en Python	14
5.1. Código Python	14
6. Resultados	16
6.1. Coeficientes del modelo LDA	16
6.2. Matrices de confusión (conjunto de prueba, $n = 150$)	16
6.3. Precisión (Accuracy) y reporte de clasificación	17
6.4. Curva ROC y AUC	18
6.5. Regiones de clasificación	18
6.6. Predicción de un nuevo estudiante	20

7. Discusión y Conclusiones	21
7.1. Discusión	21
7.2. Conclusiones	21
7.3. Recomendaciones	22
Bibliografía	23
A. Anexos	24
A.1. Anexo A: Script completo en R	24
A.2. Anexo B: Script completo en Python	24
A.3. Anexo C: Dataset	24

Índice de figuras

3.1. Distribución de Study Hours y Previous Exam Score por resultado (0 = Fail, 1 = Pass)	10
3.2. Study Hours vs Previous Exam Score, coloreado por resultado	11
6.1. Matriz de confusión – LDA	17
6.2. Matriz de confusión – QDA	17
6.3. Curva ROC comparativa: LDA vs QDA	18
6.4. Región de clasificación – LDA (frontera lineal/recta)	19
6.5. Región de clasificación – QDA (frontera cuadrática/curva)	19

Índice de cuadros

2.1. Comparación entre LDA y QDA	8
3.1. Variables del dataset	9
3.2. Estadísticos descriptivos del dataset	9
6.1. Matriz de confusión – Modelo LDA	16
6.2. Matriz de confusión – Modelo QDA	16
6.3. Comparación de desempeño en el conjunto de prueba	17
6.4. Errores de clasificación	17
6.5. Predicción para un nuevo estudiante (Study Hours = 6, Previous Exam Score = 75)	20

Capítulo 1

Introducción

El Análisis Discriminante es una técnica de aprendizaje supervisado utilizada para clasificar observaciones dentro de grupos previamente conocidos, a partir de un conjunto de variables predictoras cuantitativas. Existen dos variantes principales: el **Análisis Discriminante Lineal (LDA, por sus siglas en inglés)** y el **Análisis Discriminante Cuadrático (QDA)**, las cuales se diferencian principalmente en el supuesto sobre la matriz de covarianzas de los grupos.

En el presente informe se aplica el LDA y el QDA a un problema real de predicción académica: determinar si un estudiante **aprobará o desaprobará** un examen (*Pass/Fail*) en función de dos variables:

- **Study Hours:** número de horas que el estudiante dedicó al estudio.
- **Previous Exam Score:** nota obtenida en un examen previo.

El objetivo es comparar el desempeño de ambos modelos, identificar cuál se ajusta mejor a la naturaleza de los datos y explicar, desde un punto de vista estadístico, por qué uno supera al otro.

1.1. Objetivos

1.1.1. Objetivo general

Aplicar el Análisis Discriminante Lineal y Cuadrático para clasificar a estudiantes en las categorías “Aprobado” y “Desaprobado”, evaluando su precisión mediante matrices de confusión, curvas ROC y validación cruzada.

1.1.2. Objetivos específicos

- Explorar gráfica y estadísticamente el comportamiento de las variables predictoras respecto a la variable de clasificación.
- Verificar los supuestos de normalidad univariante y homogeneidad de varianzas.
- Estimar los modelos LDA y QDA utilizando R y Python.
- Comparar el error de clasificación, la precisión (*accuracy*) y el área bajo la curva ROC (AUC) de ambos modelos.

- Visualizar las regiones de decisión de cada modelo.

Capítulo 2

Marco Teórico

2.1. Análisis Discriminante Lineal (LDA)

El LDA es un método de clasificación supervisada que busca una combinación lineal de las variables independientes capaz de separar de la mejor manera posible a los grupos de la variable dependiente (categórica). Esta combinación lineal recibe el nombre de *función discriminante*:

$$D = u_1X_1 + u_2X_2 + \cdots + u_kX_k \quad (2.1)$$

El procedimiento de Fisher determina el vector $\mathbf{u}$ que maximiza el cociente entre la variabilidad entre grupos y la variabilidad intra-grupos:

$$\frac{\text{variabilidad entre grupos}}{\text{variabilidad intra grupos}} = \frac{\mathbf{u}'\mathbf{B}\mathbf{u}}{\mathbf{u}'\mathbf{W}\mathbf{u}} \quad (2.2)$$

donde $\mathbf{W}$ es la matriz de suma de cuadrados intra-grupos y $\mathbf{B}$ es la matriz de suma de cuadrados inter-grupos.

Bajo el enfoque bayesiano, asumiendo que cada clase k sigue una distribución normal multivariante con **matriz de covarianzas común** Σ , la función discriminante de Bayes resulta:

$$\hat{\delta}_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log(\pi_k) \quad (2.3)$$

Esta función es **lineal** respecto a x , de ahí el nombre del método. La observación se clasifica en la clase k para la cual $\hat{\delta}_k(x)$ es máxima.

2.2. Análisis Discriminante Cuadrático (QDA)

El QDA relaja el supuesto de igualdad de matrices de covarianza entre los grupos, permitiendo que cada clase k tenga su propia matriz Σ_k . Esto da lugar a una función discriminante **cuadrática**:

$$\hat{\delta}_k(x) = -\frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) + \log(\pi_k) \quad (2.4)$$

Al no asumir homogeneidad de varianzas, el QDA puede generar **fronteras de decisión curvas** (cuadráticas), lo que le permite ajustarse mejor a problemas donde las clases no se separan mediante una línea recta.

2.3. LDA vs QDA: ¿Cuándo usar cada uno?

Cuadro 2.1: Comparación entre LDA y QDA

Criterio	LDA	QDA
Matriz de covarianzas	Igual en todos los grupos	Distinta para cada grupo
Frontera de decisión	Lineal (recta/hiperplano)	Cuadrática (curva)
Número de parámetros	Menor	Mayor (crece con p^2 por clase)
Comportamiento con poco n	Más estable	Puede sobreajustar
Cuándo usarlo	Clases con dispersión similar	Clases con dispersión distinta o relación no lineal

2.4. Métricas de evaluación

- **Matriz de confusión:** tabla que cruza la clase real con la clase predicha, mostrando verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN).
- **Accuracy (precisión global):**
$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}$$
- **Curva ROC y AUC:** representa la relación entre la tasa de verdaderos positivos (sensibilidad) y la tasa de falsos positivos para distintos puntos de corte. El AUC (área bajo la curva) resume la capacidad discriminante global del modelo: cuanto más cercano a 1, mejor.
- **Validación cruzada (k-fold):** técnica que divide los datos en k particiones, entrenando y evaluando el modelo k veces para obtener una estimación más robusta de su capacidad de generalización.

Capítulo 3

Datos y Metodología

3.1. Descripción del dataset

El dataset utilizado, `student_exam_data_new.csv`, contiene **500 observaciones** de estudiantes con las siguientes variables:

Cuadro 3.1: Variables del dataset

Variable	Tipo	Descripción
Study Hours	Cuantitativa continua	Horas dedicadas al estudio (1 – 10 hrs)
Previous Exam Score	Cuantitativa continua	Nota del examen previo (40 – 100 pts)
Pass/Fail	Cualitativa binaria	0 = Desaprobado, 1 = Aprobado

Cuadro 3.2: Estadísticos descriptivos del dataset

Estadístico	Study Hours	Previous Exam Score
Mínimo	1.05	40.28
Máximo	9.94	99.98
Media	5.55	68.39
Mediana	5.62	68.31

La proporción de clases es **63.2 % Desaprobados** (clase 0) y **36.8 % Aprobados** (clase 1), por lo que las probabilidades previas (π_k) utilizadas en ambos modelos son:

$$\hat{\pi}_{\text{Fail}} = 0,632 \quad \hat{\pi}_{\text{Pass}} = 0,368 \quad (3.1)$$

3.2. Exploración gráfica

La Figura 3.1 muestra la distribución de cada variable predictora separada por clase. Se observa que los estudiantes que aprueban tienden a concentrarse en valores más altos de ambas variables, aunque con cierto solapamiento.




Figura 3.1: Distribución de Study Hours y Previous Exam Score por resultado (0 = Fail, 1 = Pass)

La Figura 3.2 presenta el diagrama de dispersión conjunto de ambas variables. Aquí se aprecia con mayor claridad el patrón clave del problema: los estudiantes **aprobados (verde)** se concentran preferentemente en la esquina superior derecha del gráfico, es decir, donde **ambas** variables (horas de estudio y nota previa) son simultáneamente altas. Este patrón de tipo “esquina” o interacción entre variables es una señal de que la frontera de separación entre clases podría no ser una simple línea recta.




Figura 3.2: Study Hours vs Previous Exam Score, coloreado por resultado

3.3. Prueba de normalidad

Se aplicó la prueba de Shapiro-Wilk para evaluar la normalidad univariante de cada variable dentro de cada grupo. En las cuatro combinaciones (grupo $\times$ variable) se obtuvo un p -valor $< 0,001$, lo que indica evidencia significativa de **falta de normalidad univariante**. Esto es relevante porque tanto LDA como QDA asumen normalidad multivariante dentro de cada clase; el incumplimiento de este supuesto sugiere que las conclusiones basadas en pruebas de significación deben tomarse con cautela, aunque, como indica la literatura (Li, Zhu y Ogihara, citado en el documento base del curso), *ambos métodos son razonablemente robustos* ante violaciones moderadas de este supuesto y pueden seguir logrando una buena capacidad de clasificación.

3.4. Partición de los datos

Los datos fueron divididos aleatoriamente (`random_state = 123 / set.seed(123)`) en:

- **Conjunto de entrenamiento:** 70 % (350 observaciones)
- **Conjunto de prueba:** 30 % (150 observaciones)

Adicionalmente se aplicó **validación cruzada de 10 particiones (10-fold)** sobre el dataset completo para obtener una estimación más robusta del desempeño de cada modelo.

Capítulo 4

Implementación en RStudio

4.1. Código R

A continuación se presenta el script en R utilizado para estimar los modelos LDA y QDA mediante la función `lda()` y `qda()` del paquete MASS.

Listing 4.1: Carga de datos y modelo LDA en R

```
1 # Carga del dataset
2 datos <- read.csv("student_exam_data_new.csv", header = TRUE)
3 names(datos) <- c("study_hours", "prev_score", "pass_fail")
4 datos$pass_fail <- as.factor(datos$pass_fail)
5 levels(datos$pass_fail) <- c("Fail", "Pass")
6
7 # Particion 70/30
8 set.seed(123)
9 n <- nrow(datos)
10 idx_train <- sample(seq_len(n), size = 0.7 * n)
11 train <- datos[idx_train, ]
12 test <- datos[-idx_train, ]
13
14 # Modelo LDA
15 library(MASS)
16 modelo_lda <- lda(pass_fail ~ study_hours + prev_score, data =
17   train)
18 pred_lda <- predict(modelo_lda, newdata = test)
19
20 # Matriz de confusion
21 table(test$pass_fail, pred_lda$class,
22   dnn = c("Clase real", "Clase predicha"))
23
24 # Modelo QDA
25 modelo_qda <- qda(pass_fail ~ study_hours + prev_score, data =
26   train)
27 pred_qda <- predict(modelo_qda, newdata = test)
```

Listing 4.2: Curva ROC y validacion cruzada en R

```
1 library(pROC)
2 roc_lda <- roc(test$pass_fail, pred_lda$posterior[, "Pass"])
3 roc_qda <- roc(test$pass_fail, pred_qda$posterior[, "Pass"])
```

```
4 auc(roc_lda); auc(roc_qda)
5
6 library(caret)
7 lda_cv <- train(pass_fail ~ study_hours + prev_score, data = datos,
8                 method = "lda",
9                 trControl = trainControl(method = "cv", number =
10                                         10))
11 qda_cv <- train(pass_fail ~ study_hours + prev_score, data = datos,
12                 method = "qda",
13                 trControl = trainControl(method = "cv", number =
14                                         10))
```

El script completo (`analisis_discriminante_estudiantes.R`) se adjunta como anexo y reproduce, además, las pruebas de normalidad multivariante (paquete `MVN`), la prueba M de Box (`biotools`) y las regiones de clasificación con `klaR`.

Capítulo 5

Implementación en Python

5.1. Código Python

En Python se utilizó la librería `scikit-learn`, concretamente las clases `LinearDiscriminantAnalysis` y `QuadraticDiscriminantAnalysis` del módulo `sklearn.discriminant_analysis`.

Listing 5.1: Carga de datos y modelos LDA/QDA en Python

```
1 import pandas as pd
2 from sklearn.discriminant_analysis import (
3     LinearDiscriminantAnalysis as LDA,
4     QuadraticDiscriminantAnalysis as QDA,
5 )
6 from sklearn.model_selection import train_test_split
7 from sklearn.metrics import confusion_matrix, accuracy_score
8
9 # Carga del dataset
10 datos = pd.read_csv("student_exam_data_new.csv")
11 datos.columns = ["study_hours", "prev_score", "pass_fail"]
12 X = datos[["study_hours", "prev_score"]]
13 y = datos["pass_fail"]
14
15 # Particion 70/30
16 X_train, X_test, y_train, y_test = train_test_split(
17     X, y, test_size=0.3, random_state=123, stratify=y
18 )
19
20 # Modelo LDA
21 modelo_lda = LDA(solver="svd", store_covariance=True)
22 modelo_lda.fit(X_train, y_train)
23 clase_lda = modelo_lda.predict(X_test)
24
25 # Modelo QDA
26 modelo_qda = QDA(store_covariance=True)
27 modelo_qda.fit(X_train, y_train)
28 clase_qda = modelo_qda.predict(X_test)
29
30 print("Accuracy LDA:", accuracy_score(y_test, clase_lda))
31 print("Accuracy QDA:", accuracy_score(y_test, clase_qda))
```

Listing 5.2: Curva ROC y validacion cruzada en Python

```
1 from sklearn.metrics import roc_curve, auc
2 from sklearn.model_selection import cross_val_score
3
4 post_lda = modelo_lda.predict_proba(X_test)
5 post_qda = modelo_qda.predict_proba(X_test)
6
7 fpr_lda, tpr_lda, _ = roc_curve(y_test, post_lda[:, 1])
8 fpr_qda, tpr_qda, _ = roc_curve(y_test, post_qda[:, 1])
9 auc_lda = auc(fpr_lda, tpr_lda)
10 auc_qda = auc(fpr_qda, tpr_qda)
11
12 cv_lda = cross_val_score(LDA(), X, y, cv=10)
13 cv_qda = cross_val_score(QDA(), X, y, cv=10)
```

El script completo (`analisis_discriminante_estudiantes.py`) se adjunta como anexo.

Capítulo 6

Resultados

6.1. Coeficientes del modelo LDA

La función discriminante lineal estimada sobre el conjunto de entrenamiento es:

$$D = 0,9295 (\text{study_hours}) + 0,1069 (\text{prev_score}) - 13,596 \quad (6.1)$$

El coeficiente de `study_hours` (0.9295) es considerablemente mayor que el de `prev_score` (0.1069), lo que sugiere que, dentro de un modelo lineal, las horas de estudio aportan más peso discriminante que la nota previa.

6.2. Matrices de confusión (conjunto de prueba, $n = 150$)

Cuadro 6.1: Matriz de confusión – Modelo LDA

		Clase predicha	
		Fail	Pass
Clase real	Fail	84	11
	Pass	11	44

Cuadro 6.2: Matriz de confusión – Modelo QDA

		Clase predicha	
		Fail	Pass
Clase real	Fail	92	3
	Pass	6	49




Figura 6.1: Matriz de confusión – LDA




Figura 6.2: Matriz de confusión – QDA

6.3. Precisión (Accuracy) y reporte de clasificación

Cuadro 6.3: Comparación de desempeño en el conjunto de prueba

Modelo	Accuracy	Precision (Pass)	Recall (Pass)	F1-score (Pass)
LDA	85.33 %	0.80	0.80	0.80
QDA	94.00 %	0.94	0.89	0.92

Cuadro 6.4: Errores de clasificación

Modelo	Error de clasificación (test)	Accuracy validación cruzada (10-fold)
LDA	14.67 %	0,864 ± 0,079
QDA	6.00 %	0,936 ± 0,046

El modelo QDA reduce el error de clasificación de **14.67 % a 6.00 %** respecto al LDA, una mejora sustancial que se mantiene consistente en la validación cruzada (93.6 % vs 86.4 % de accuracy promedio).

6.4. Curva ROC y AUC




Figura 6.3: Curva ROC comparativa: LDA vs QDA

La curva ROC del modelo QDA se ubica consistentemente por encima de la curva del LDA, confirmando un mayor poder discriminante (mayor AUC) en todos los puntos de corte posibles.

6.5. Regiones de clasificación

Las Figuras 6.4 y 6.5 muestran las regiones de decisión proyectadas sobre el plano *Study Hours vs Previous Exam Score*.




Figura 6.4: Región de clasificación – LDA (frontera lineal/recta)




Figura 6.5: Región de clasificación – QDA (frontera cuadrática/curva)

Interpretación clave: en la Figura 6.4 (LDA) la frontera de decisión es una línea recta inclinada, ya que el modelo lineal solo puede separar el espacio mediante un hiperplano. Sin embargo, en la Figura 6.5 (QDA) la frontera se curva formando una especie de “esquina” alrededor de la región donde ambas variables son altas. Esta forma cuadrática se ajusta mucho mejor al patrón real de los datos observado en la

Figura 3.2: un estudiante aprueba principalmente cuando **tanto** las horas de estudio **como** la nota previa son suficientemente altas, una relación de tipo interacción que el LDA, al ser estrictamente lineal, no puede representar con precisión.

6.6. Predicción de un nuevo estudiante

Se evaluó un caso hipotético: un estudiante con **6 horas de estudio** y **nota previa de 75 puntos**.

Cuadro 6.5: Predicción para un nuevo estudiante (Study Hours = 6, Previous Exam Score = 75)

Modelo	Clase predicha	P(Fail)	P(Pass)
LDA	Fail (límite)	50.00 %	49.99 %
QDA	Pass	37.90 %	62.10 %

Este caso es particularmente ilustrativo: el LDA ubica al estudiante prácticamente en el límite de decisión (probabilidades casi 50/50), mientras que el QDA, al capturar la curvatura real de la frontera, lo clasifica con mayor confianza como “Pass”. Esto evidencia nuevamente la ventaja del QDA para este problema específico.

Capítulo 7

Discusión y Conclusiones

7.1. Discusión

Los resultados obtenidos muestran que el **QDA supera de manera consistente al LDA** en las tres métricas evaluadas: accuracy en el conjunto de prueba (94.00 % vs 85.33 %), accuracy en validación cruzada (93.6 % vs 86.4 %) y área bajo la curva ROC. Esto se explica por la naturaleza de los datos: la separación entre estudiantes que aprueban y desaprueban no sigue un patrón lineal, sino una interacción entre ambas variables (se requiere que ambas sean altas simultáneamente), lo cual genera una frontera de decisión naturalmente curva que el QDA puede modelar y el LDA no.

Cabe destacar que, si bien las pruebas de Shapiro-Wilk mostraron evidencia de falta de normalidad univariante en las cuatro combinaciones grupo-variable, ambos modelos lograron una capacidad de clasificación aceptable a buena, lo que confirma la robustez relativa de estas técnicas frente a desviaciones moderadas de sus supuestos teóricos, tal como se señala en la literatura especializada del curso.

7.2. Conclusiones

1. Se implementó exitosamente el Análisis Discriminante Lineal y Cuadrático tanto en R (paquete **MASS**) como en Python (**scikit-learn**), obteniendo resultados coherentes entre ambos lenguajes.
2. El modelo QDA presentó un desempeño superior al LDA en todas las métricas evaluadas, reduciendo el error de clasificación en el conjunto de prueba de 14.67 % a 6.00 %.
3. La superioridad del QDA se debe a que la relación real entre las horas de estudio, la nota previa y el resultado de aprobación no es lineal, sino que responde a una lógica de “ambas variables deben ser altas”, generando una frontera de decisión curva.
4. La validación cruzada de 10 particiones confirmó que la diferencia de desempeño entre ambos modelos no se debe al azar de una única partición train/test, sino que es un patrón estable.
5. Se recomienda, para este tipo de problemas académicos donde pueden existir

interacciones entre variables predictoras, evaluar siempre tanto LDA como QDA (y, de ser necesario, modelos no lineales adicionales) antes de seleccionar el modelo final.

7.3. Recomendaciones

- Incorporar variables adicionales (por ejemplo, asistencia a clases, horas de sueño, nivel socioeconómico) que podrían mejorar aún más la capacidad predictiva del modelo.
- Evaluar el desempeño de los modelos con un conjunto de datos de validación externo (de otro periodo académico) para confirmar su capacidad de generalización.
- Explorar modelos adicionales como Regresión Logística o árboles de decisión como referencia comparativa frente a LDA y QDA.

Bibliografía

- [1] Carpio Vargas, E. E. (2024). *Análisis discriminante lineal (LDA)*. FINESI, Universidad Nacional del Altiplano.
- [2] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2.^a ed.). Springer.
- [3] Li, T., Zhu, S., & Ogihara, M. *Using discriminant analysis for multi-class classification: an experimental investigation*.
- [4] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [5] Venables, W. N., & Ripley, B. D. (2002). *Modern Applied Statistics with S* (4.^a ed.). Springer. [Paquete MASS]

Apéndice A

Anexos

A.1. Anexo A: Script completo en R

El archivo `analisis_discriminante_estudiantes.R` contiene el script completo: carga de datos, exploración gráfica, pruebas de normalidad y homogeneidad de varianzas, estimación de los modelos LDA y QDA, matrices de confusión, curvas ROC, validación cruzada y regiones de clasificación.

A.2. Anexo B: Script completo en Python

El archivo `analisis_discriminante_estudiantes.py` contiene el script completo equivalente, implementado con `pandas`, `scikit-learn`, `matplotlib` y `seaborn`.

A.3. Anexo C: Dataset

El archivo `student_exam_data_new.csv` contiene las 500 observaciones utilizadas en el presente análisis.