

UNIVERSIDAD NACIONAL DEL ALTIPLANO
FACULTAD DE INGENIERÍA ESTADÍSTICA E INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA ESTADÍSTICA E
INFORMÁTICA



Reclasificación de buenos clientes con Análisis Discriminante (LDA)

Informe aplicado sobre cartera de créditos Cash –
Compartamos

Docente: Ing. Eloy Carpio Vargas

Presentado por: Quispe Holguin Alexander

Curso: Aprendizaje Supervisado

Semestre: VII – 2026-I

Puno – Perú
2026

Índice general

Índice general	1
Índice de figuras	3
Índice de cuadros	4
1. Introducción	5
2. Marco Teórico	6
2.1. Fundamento del Análisis Discriminante Lineal	6
2.2. Supuestos del modelo	6
2.3. Evaluación del modelo	7
3. Metodología	8
3.1. Fuente de datos	8
3.2. Variable dependiente (grupos)	8
3.3. Variables independientes (predictoras)	8
3.4. Tratamiento de datos faltantes	9
3.5. Estandarización de variables	9
3.6. Software empleado	9
4. Análisis Exploratorio de Datos	10
4.1. Distribución de las variables por grupo	10
4.2. Análisis de caja y bigotes (boxplots)	11
4.3. Matriz de correlación	12
4.4. Dispersión entre variables de mora y atraso	13
5. Verificación de Supuestos del Modelo	15
5.1. Normalidad univariante (prueba de Shapiro-Wilk)	15
5.2. Homogeneidad de matrices de covarianza (prueba M de Box)	15
5.3. Interpretación conjunta de los supuestos	16
6. Estimación del Modelo Discriminante	17
6.1. Probabilidades previas (prior probabilities)	17
6.2. Funciones discriminantes obtenidas	17
6.3. Coeficientes de las funciones discriminantes	18
6.4. Funciones discriminantes resultantes	19

7. Evaluación del Modelo	20
7.1. Matriz de confusión	20
7.2. Indicadores de precisión	21
7.3. Validación cruzada Leave-One-Out (LOOCV)	22
7.4. Espacio discriminante: proyección LD1 vs. LD2	22
7.5. Distribución de la puntuación discriminante LD1 por grupo	23
8. Conclusiones y Recomendaciones	24
8.1. Conclusiones	24
8.2. Recomendaciones	25
A. Anexo A: Código completo en R	26
B. Anexo B: Salida completa del modelo en R	29

Índice de figuras

4.1. Histogramas de las 12 variables predictoras, segmentadas por calificación del cliente (B, A, A+).	11
4.2. Diagramas de caja y bigotes de las variables predictoras por calificación del cliente.	12
4.3. Matriz de correlación de Pearson entre las variables predictoras. . . .	13
4.4. Diagrama de dispersión: mora promedio vs. atraso máximo del cliente, por calificación.	14
6.1. Coeficientes estandarizados de las dos funciones discriminantes lineales (LD1 y LD2).	19
7.1. Matriz de confusión del modelo LDA representada como mapa de calor.	21
7.2. Proyección de los clientes sobre el espacio discriminante LD1 – LD2. .	22
7.3. Distribución de la puntuación discriminante LD1 para cada grupo (B, A, A+).	23

Índice de cuadros

3.1. Distribución de la variable de grupo (calificación del cliente)	8
3.2. Variables independientes utilizadas en el modelo LDA	9
5.1. Resultado global de la prueba de normalidad Shapiro-Wilk	15
5.2. Resultado de la prueba M de Box	16
6.1. Probabilidades previas (prior probabilities) por grupo	17
6.2. Valores propios y proporción de varianza explicada por función discriminante	17
6.3. Coeficientes estandarizados de las funciones discriminantes lineales . .	18
7.1. Matriz de confusión del modelo LDA (clase real vs. clase predicha) . .	20
7.2. Indicadores globales de desempeño del modelo	21

Capítulo 1

Introducción

El presente informe desarrolla un **Análisis Discriminante Lineal (LDA, por sus siglas en inglés *Linear Discriminant Analysis*)** aplicado a una cartera real de clientes de créditos *Cash* de la entidad financiera Compartamos, con el objetivo de **reclasificar a los buenos clientes** a partir de sus indicadores de comportamiento de pago y de su situación financiera.

El Análisis Discriminante Lineal es, según Carpio Vargas (2024), una técnica estadística de aprendizaje supervisado cuyo objetivo es encontrar una combinación lineal de variables independientes que permita diferenciar de la mejor manera posible a los grupos definidos a priori de la variable dependiente. César Pérez López lo define como “una técnica estadística que permite asignar o clasificar nuevos individuos dentro de grupos previamente reconocidos o definidos”.

En este caso, los grupos a priori corresponden a la **calificación crediticia** que la entidad asigna a cada cliente (**A+**, **A**, **B**), y las variables independientes corresponden a indicadores cuantitativos de mora, atraso, deuda, ingresos y egresos. El propósito del análisis es doble:

1. **Explicativo:** cuantificar qué variables de comportamiento de pago y situación financiera contribuyen más a diferenciar entre clientes **A+**, **A** y **B**.
2. **Reclasificador:** corroborar, mediante una función matemática objetiva, si la calificación asignada por el analista de crédito es consistente con el comportamiento real del cliente, identificando posibles clientes mal clasificados.

Todo el procesamiento estadístico se realizó en el lenguaje **R** (versión 4.3.3), empleando la función `lda()` del paquete **MASS**, que implementa el procedimiento de Fisher descrito en el documento base del curso.

Capítulo 2

Marco Teórico

2.1. Fundamento del Análisis Discriminante Lineal

Para aplicar un análisis discriminante, la variable dependiente debe ser cualitativa con dos o más categorías de respuesta, exhaustivas y mutuamente excluyentes, y las variables independientes deben ser cuantitativas (métricas). El objetivo es obtener una función de la forma:

$$D = u_1X_1 + u_2X_2 + \cdots + u_kX_k \quad (2.1)$$

donde D es la puntuación discriminante, X_j son las variables predictoras y u_j son los coeficientes de ponderación que se obtienen maximizando el cociente entre la variabilidad **entre grupos** y la variabilidad **intra-grupos**:

$$\frac{\text{variabilidad entre grupos}}{\text{variabilidad intra grupos}} = \frac{\mathbf{u}'\mathbf{B}\mathbf{u}}{\mathbf{u}'\mathbf{W}\mathbf{u}} \quad (2.2)$$

La solución viene dada por los vectores propios de la matriz $\mathbf{W}^{-1}\mathbf{B}$ asociados a los mayores valores propios λ_i , donde $\mathbf{W}$ es la matriz de suma de cuadrados intra-grupos y $\mathbf{B}$ es la matriz de suma de cuadrados inter-grupos. El número máximo de funciones discriminantes que pueden calcularse es $\min(q - 1, p)$, siendo q el número de grupos y p el número de predictores.

2.2. Supuestos del modelo

Según el documento base (Carpio Vargas, 2024), la fiabilidad del LDA depende de tres supuestos fundamentales:

1. **Homogeneidad de varianzas:** la matriz de covarianzas intra-grupo debe ser similar en todos los grupos. Se contrasta con la prueba M de Box.
2. **Normalidad multivariante:** cada grupo debe proceder de una población con distribución normal multivariante.
3. **Ausencia de multicolinealidad severa** entre las variables independientes.

No obstante, el propio documento aclara que “en la práctica, el análisis discriminante es una técnica robusta y funciona bien, aunque las restricciones anteriores no se cumplan”, situación que se evidencia también en el ejemplo de datos *Iris* desarrollado en clase, donde a pesar de existir evidencia de no normalidad multivariante, el modelo LDA alcanzó una precisión de clasificación adecuada.

2.3. Evaluación del modelo

La precisión del modelo se evalúa mediante la **matriz de confusión**, que contrasta la clase real contra la clase predicha, y mediante el **error de entrenamiento** (*training error*):

$$\text{Training error} = \frac{\text{número de clasificaciones incorrectas}}{\text{número total de observaciones}} \times 100 \% \quad (2.3)$$

Adicionalmente, se emplea **validación cruzada Leave-One-Out (LOOCV)** para obtener una estimación menos optimista del error de clasificación, dado que el error de entrenamiento puro tiende a subestimar el error real del modelo al evaluarse sobre las mismas observaciones usadas para construirlo.

Capítulo 3

Metodología

3.1. Fuente de datos

Se utilizó la base de datos `databuenosclientes.xlsx`, correspondiente al reporte “rep_generacion_cash” de la entidad financiera, con un total de **114 clientes** activos en la modalidad de crédito Cash.

3.2. Variable dependiente (grupos)

La variable de agrupación corresponde a la columna `cliente`, que contiene la calificación crediticia vigente del cliente, con tres niveles:

Cuadro 3.1: Distribución de la variable de grupo (calificación del cliente)

Categoría	Número de clientes	Porcentaje
B	25	21.9 %
A	61	53.5 %
A+	28	24.6 %
Total	114	100.0 %

3.3. Variables independientes (predictoras)

Se seleccionaron 12 variables cuantitativas relacionadas con el comportamiento de pago y la situación financiera del cliente, excluyendo del análisis los códigos identificadores, fechas, el nombre del analista, el tipo de garantía y las columnas referidas al cónyuge (con más del 99 % de valores faltantes):

Cuadro 3.2: Variables independientes utilizadas en el modelo LDA

Variable	Descripción
monto_aprobado	Monto aprobado de cash (S/.)
mora_promedio	Mora promedio del cliente (días)
atraso_maximo	Atraso máximo histórico del cliente (días)
atraso_max_3m	Atraso máximo en los últimos 3 meses (días)
atraso_actual	Atraso actual (días)
n_creditos_vigentes	Número de créditos vigentes
deuda_compartamos	Deuda total en Compartamos (S/.)
n_empresas_sbs	Número de empresas en la SBS
deuda_sbs	Deuda directa en la SBS (S/.)
ingresos	Ingresos del cliente (S/.)
egresos	Egresos del cliente (S/.)
resultado_netto	Resultado neto (ingresos – egresos) (S/.)

3.4. Tratamiento de datos faltantes

Se identificaron valores faltantes en tres variables: `atraso_actual` (16 casos), `n_empresas_sbs` y `deuda_sbs` (3 casos cada una). En los tres casos, el valor faltante corresponde a la ausencia de registro de atraso o de deuda en el sistema financiero, por lo que se imputaron como cero (0), siguiendo el criterio de que la falta de información en estas variables específicas no es aleatoria sino que refleja una condición real del cliente (ausencia de atraso o de deuda reportada).

3.5. Estandarización de variables

Dado que las variables predictoras presentan escalas muy distintas (montos en soles de varios miles frente a conteos en unidades), se estandarizaron todas las variables predictoras (media 0, desviación estándar 1) antes de estimar el modelo LDA. Esta transformación no afecta las puntuaciones discriminantes ni la clasificación resultante, pero permite comparar de manera justa la magnitud de los coeficientes de las funciones discriminantes.

3.6. Software empleado

Todo el procesamiento se realizó en **R 4.3.3**, utilizando los paquetes **MASS** (función `lda()`), **readxl**, **ggplot2**, **ggpubr**, **corrplot**, **reshape2**, **dplyr** y **scales**. El código completo se presenta en el Anexo A.

Capítulo 4

Análisis Exploratorio de Datos

4.1. Distribución de las variables por grupo

La Figura 4.1 muestra la distribución de cada variable predictora segmentada por calificación del cliente. Se observa un solapamiento considerable entre los tres grupos en la mayoría de las variables, lo cual sugiere que, de manera individual, ninguna variable separa completamente a los clientes B, A y A+.




Figura 4.1: Histogramas de las 12 variables predictoras, segmentadas por calificación del cliente (B, A, A+).

4.2. Análisis de caja y bigotes (boxplots)

La Figura 4.2 permite visualizar con mayor claridad la dispersión, la mediana y los valores atípicos de cada variable en cada grupo. Se aprecia que, en variables como *deuda_sbs* e *ingresos*, el grupo A presenta medianas más altas que B y A+, mientras que en variables de atraso la diferencia entre grupos es mínima.




Figura 4.2: Diagramas de caja y bigotes de las variables predictoras por calificación del cliente.

4.3. Matriz de correlación

La Figura 4.3 presenta la matriz de correlación entre las 12 variables predictoras. Destaca una correlación muy alta entre **ingresos** y **egresos** ($r = 0,96$), y entre **deuda_compartamos** y **deuda_sbs** ($r = 0,75$), lo cual constituye evidencia de **multicolinealidad**, uno de los supuestos que el documento base recomienda verificar antes de interpretar los coeficientes individuales del modelo.




Figura 4.3: Matriz de correlación de Pearson entre las variables predictoras.

4.4. Dispersión entre variables de mora y atraso

La Figura 4.4 muestra la relación entre la mora promedio y el atraso máximo del cliente, coloreada según su calificación. Se observa una relación positiva entre ambas variables, pero sin una separación clara entre las tres categorías de calificación, lo que anticipa que el poder discriminante del modelo será moderado.




Figura 4.4: Diagrama de dispersión: mora promedio vs. atraso máximo del cliente, por calificación.

Capítulo 5

Verificación de Supuestos del Modelo

5.1. Normalidad univariante (prueba de Shapiro-Wilk)

Se aplicó la prueba de Shapiro-Wilk a cada una de las 12 variables predictoras, dentro de cada uno de los tres grupos (36 combinaciones variable-grupo en total). Los resultados se resumen en la Tabla 5.1.

Cuadro 5.1: Resultado global de la prueba de normalidad Shapiro-Wilk

Indicador	Valor
Combinaciones variable-grupo evaluadas	36
Combinaciones con $p < 0,05$ (no normales)	36
Porcentaje de no normalidad	100.0 %

El resultado indica que **ninguna** de las 36 combinaciones variable-grupo sigue una distribución normal univariante, lo que constituye evidencia fuerte en contra del supuesto de normalidad multivariante exigido por el LDA clásico. Este hallazgo es consistente con la naturaleza de los datos financieros, que típicamente presentan distribuciones asimétricas y colas pesadas (montos de crédito, deudas y atrasos rara vez se distribuyen de forma simétrica).

5.2. Homogeneidad de matrices de covarianza (prueba M de Box)

Se calculó el estadístico M de Box para contrastar la hipótesis nula de igualdad de las matrices de varianzas-covarianzas entre los tres grupos:

Cuadro 5.2: Resultado de la prueba M de Box

Estadístico	Valor
Chi-cuadrado aproximado	1495.482
Grados de libertad	156
Valor p	$< 0,00001$

Con un valor p prácticamente nulo, se **rechaza la hipótesis de homogeneidad de covarianzas**, incluso bajo el umbral conservador de significancia de 0.001 recomendado por Tabachnick y Fidell (2001) para esta prueba, dada su elevada sensibilidad a la falta de normalidad multivariante.

5.3. Interpretación conjunta de los supuestos

Tal como advierte el documento base del curso, la prueba M de Box es muy sensible a desviaciones de la normalidad multivariante, por lo que un resultado significativo puede deberse tanto a una matriz de covarianzas distinta entre grupos como a la falta de normalidad detectada en la sección anterior. En cualquiera de los dos escenarios, los supuestos clásicos del LDA no se cumplen estrictamente en este conjunto de datos.

Sin embargo, siguiendo el mismo criterio aplicado en el ejemplo del conjunto de datos *Iris* desarrollado en el curso –donde tampoco se cumplía la normalidad multivariante y aun así el LDA alcanzó una precisión aceptable– se optó por mantener el LDA como técnica principal, evaluando honestamente su desempeño real mediante matriz de confusión y validación cruzada, en lugar de descartarlo de forma automática.

Capítulo 6

Estimación del Modelo Discriminante

6.1. Probabilidades previas (prior probabilities)

Al no disponer de información sobre la abundancia poblacional real de cada categoría, las probabilidades previas se estimaron como la proporción muestral de cada grupo:

Cuadro 6.1: Probabilidades previas (prior probabilities) por grupo

Grupo	Probabilidad previa
B	0.2193
A	0.5351
A+	0.2456

6.2. Funciones discriminantes obtenidas

Al tratarse de tres grupos (B, A, A+), el número máximo de funciones discriminantes que pueden calcularse es $\min(q - 1, p) = \min(2, 12) = 2$. La Tabla 6.2 presenta el poder discriminante de cada función, medido a través de su valor propio (λ_i) y la proporción de varianza explicada (*proportion of trace*).

Cuadro 6.2: Valores propios y proporción de varianza explicada por función discriminante

Función	Valor propio (λ)	Proporción de varianza
LD1	20.8598	81.2 %
LD2	4.8304	18.8 %

La primera función discriminante (LD1) concentra el 81.2 % de la capacidad total del modelo para separar a los tres grupos, mientras que la segunda función (LD2) aporta el 18.8 % restante.

6.3. Coeficientes de las funciones discriminantes

La Tabla 6.3 presenta los coeficientes estandarizados de ambas funciones discriminantes. Coeficientes de mayor magnitud absoluta indican mayor contribución relativa de esa variable a la separación entre grupos.

Cuadro 6.3: Coeficientes estandarizados de las funciones discriminantes lineales

Variable	LD1	LD2
monto_aprobado	0.8622	-0.4390
mora_promedio	0.0266	-0.4282
atraso_maximo	0.3205	0.4947
atraso_max_3m	-0.4565	0.2852
atraso_actual	-0.1178	-0.5299
n_creditos_vigentes	0.1555	-0.3139
deuda_compartamos	0.1309	-0.5936
n_empresas_sbs	-0.6917	-0.1823
deuda_sbs	-0.6157	0.3746
ingresos	0.8368	-0.0587
egresos	-0.6236	-0.2685
resultado_neto	-0.5725	-0.0100

La Figura 6.1 representa gráficamente estos coeficientes. En la primera función discriminante (LD1), las variables con mayor peso son `monto_aprobado` (+0.862) e `ingresos` (+0.837), en sentido positivo, y `n_empresas_sbs` (-0.692) y `egresos` (-0.624), en sentido negativo. Esto sugiere que LD1 separa principalmente a los clientes con mayor monto e ingresos, y menor número de entidades financieras donde mantienen deuda, de aquellos en la situación opuesta.




Figura 6.1: Coeficientes estandarizados de las dos funciones discriminantes lineales (LD1 y LD2).

6.4. Funciones discriminantes resultantes

A partir de los coeficientes obtenidos, las dos funciones discriminantes lineales del modelo quedan expresadas (de forma resumida, con las variables de mayor peso) como:

$$LD1 = 0,862 (\text{monto_aprobado}) + 0,837 (\text{ingresos}) - 0,692 (\text{n_empresas_sbs}) - 0,624 (\text{egresos}) - 0,616 (\text{deuda_sbs}) - 0,573 (\text{resultado_neto}) + \dots \quad (6.1)$$

$$LD2 = -0,594 (\text{deuda_compartamos}) - 0,530 (\text{atraso_actual}) + 0,495 (\text{atraso_maximo}) - 0,439 (\text{monto_aprobado}) - 0,428 (\text{mora_promedio}) + \dots \quad (6.2)$$

Capítulo 7

Evaluación del Modelo

7.1. Matriz de confusión

La Tabla 7.1 presenta la matriz de confusión obtenida al clasificar las 114 observaciones originales con el modelo LDA estimado (error de entrenamiento o *training error*).

Cuadro 7.1: Matriz de confusión del modelo LDA (clase real vs. clase predicha)

		Clase predicha		
		B	A	A+
Clase real	B	3	20	2
	A	3	51	7
	A+	2	9	17

La Figura 7.1 representa esta misma matriz como mapa de calor, facilitando la identificación visual de la diagonal principal (clasificaciones correctas) frente a los errores de clasificación.




Figura 7.1: Matriz de confusión del modelo LDA representada como mapa de calor.

7.2. Indicadores de precisión

Cuadro 7.2: Indicadores globales de desempeño del modelo

Indicador	Valor
Training error (error de entrenamiento)	37.72 %
Accuracy (precisión global)	62.28 %
Error de clasificación con LOOCV	62.28 %

El modelo clasifica correctamente al **62.28 %** de los clientes. Por categoría, el desempeño es heterogéneo:

- **Grupo A (mayoritario, 61 clientes):** 83.6 % correctamente clasificados, el mejor desempeño relativo del modelo.
- **Grupo A+ (28 clientes):** 60.7 % correctamente clasificados; el 32.1 % de los clientes A+ es confundido con la categoría A, lo cual es razonable dado que ambas son categorías de buen comportamiento de pago.
- **Grupo B (25 clientes):** solo 12.0 % correctamente clasificado; el 80.0 % de los clientes B es clasificado por el modelo como A, lo que sugiere que, en fun-

ción de su comportamiento de pago e indicadores financieros, muchos clientes calificados como B se comportan de manera muy similar a los clientes A.

7.3. Validación cruzada Leave-One-Out (LOOCV)

Para evitar el optimismo del error de entrenamiento, se recalculó el modelo utilizando validación cruzada *Leave-One-Out*, donde cada observación es clasificada utilizando un modelo entrenado con las restantes 113 observaciones. El error de clasificación obtenido por este método fue de **62.28 %**, muy similar al error de entrenamiento (37.72 % de *accuracy* en entrenamiento equivale a 62.28 % de error). Esta coincidencia indica que **el modelo no presenta sobreajuste (overfitting)**: el desempeño que se observa sobre los datos de entrenamiento es representativo del desempeño esperado sobre clientes nuevos no vistos por el modelo.

7.4. Espacio discriminante: proyección LD1 vs. LD2

La Figura 7.2 muestra a los 114 clientes proyectados sobre el plano formado por las dos funciones discriminantes (LD1, LD2), coloreados según su calificación real. Las elipses representan la región de concentración (68 % de confianza) de cada grupo.




Figura 7.2: Proyección de los clientes sobre el espacio discriminante LD1 – LD2.

Se observa un solapamiento considerable entre las tres elipses, particularmente entre los grupos A y A+, lo cual es coherente con el nivel de precisión moderado

(62.28 %) obtenido en la matriz de confusión. El grupo B, aunque tiene una elipse desplazada hacia valores más bajos de LD1, comparte una amplia zona común con el grupo A, lo que explica por qué la mayoría de los clientes B reales son clasificados por el modelo como A.

7.5. Distribución de la puntuación discriminante LD1 por grupo

La Figura 7.3 presenta los histogramas de la primera función discriminante (LD1) para cada uno de los tres grupos, de forma análoga al gráfico `plot(modelo_lda)` presentado en el documento base del curso para el ejemplo de insectos.




Figura 7.3: Distribución de la puntuación discriminante LD1 para cada grupo (B, A, A+).

Capítulo 8

Conclusiones y Recomendaciones

8.1. Conclusiones

1. El modelo de Análisis Discriminante Lineal estimado sobre los 114 clientes de la cartera Cash logra una precisión global de clasificación del **62.28 %**, con un comportamiento estable entre el error de entrenamiento y el error obtenido mediante validación cruzada Leave-One-Out, lo que descarta sobreajuste.
2. Los supuestos clásicos del LDA –normalidad multivariante y homogeneidad de matrices de covarianza– **no se cumplen** en este conjunto de datos (100 % de las combinaciones variable-grupo resultaron no normales según Shapiro-Wilk, y la prueba M de Box rechazó la homogeneidad de covarianzas con un valor p prácticamente nulo). No obstante, siguiendo el mismo criterio aplicado en el documento base para el conjunto de datos *Iris*, se optó por reportar honestamente el desempeño real del modelo en lugar de descartarlo de forma automática.
3. La primera función discriminante (LD1) concentra el 81.2 % del poder de discriminación total del modelo, y está dominada principalmente por el **monto aprobado**, los **ingresos**, el **número de empresas en la SBS** y los **egresos** del cliente.
4. El modelo discrimina razonablemente bien al grupo **A** (83.6 % de aciertos), de manera aceptable al grupo **A+** (60.7 % de aciertos, con la mayor parte del error concentrado en confusión con el grupo A, categorías ambas de buen comportamiento), pero **tiene serias dificultades para identificar al grupo B** (solo 12.0 % de aciertos), siendo clasificado mayoritariamente como A.
5. Esto sugiere que, en función de las variables cuantitativas de comportamiento de pago e indicadores financieros disponibles, una proporción importante de los clientes calificados internamente como B exhibe un perfil de riesgo muy similar al de los clientes A, lo que podría constituir una oportunidad de revisión de la política de calificación vigente.
6. Se detectó multicolinealidad relevante entre **ingresos** y **egresos** ($r = 0,96$) y entre **deuda_compartamos** y **deuda_sbs** ($r = 0,75$), lo que reduce la capacidad

explicativa individual de estas variables y debe tenerse en cuenta al interpretar sus coeficientes por separado.

8.2. Recomendaciones

1. Evaluar la aplicación de un **Análisis Discriminante Cuadrático (QDA)** como alternativa, dado que la prueba M de Box rechazó el supuesto de homogeneidad de covarianzas; el QDA no exige matrices de covarianza iguales entre grupos.
2. Explorar la **regresión logística multinomial** como técnica complementaria, dado que el documento base recomienda esta alternativa cuando los supuestos de normalidad multivariante no se cumplen.
3. Reducir la multicolinealidad detectada, por ejemplo retirando **egresos** (manteniendo **ingresos** y **resultado_netto**) o aplicando un análisis de componentes principales previo.
4. Revisar de manera particular los criterios de calificación del segmento **B**, dado el alto porcentaje de clientes de este grupo cuyo perfil cuantitativo se asemeja más al de un cliente A.
5. Ampliar el tamaño de muestra del grupo B (actualmente el más pequeño, con 25 observaciones) en futuros levantamientos de información, a fin de mejorar la estabilidad de las estimaciones para esta categoría.

Apéndice A

Anexo A: Código completo en R

A continuación se presenta el código completo en R utilizado para desarrollar el análisis discriminante, replicando la estructura de 6 pasos descrita en el documento base del curso: carga y preparación de datos, exploración gráfica, verificación de supuestos, estimación del modelo, evaluación y visualización del espacio discriminante.

Listing A.1: Script completo de R: Análisis Discriminante Lineal aplicado a la reclasificación de clientes

```
1 #####
2 # ANALISIS DISCRIMINANTE LINEAL (LDA)
3 # Reclasificación de Buenos Clientes - Compartamos
4 # Basado en: Carpio Vargas, E.E. (2024). "Análisis discriminante (LDA)"
5 # FINESI - 2024
6 #####
7
8 options(scipen = 999)
9 set.seed(123)
10
11 library(readxl)
12 library(MASS)
13 library(ggplot2)
14 library(gridExtra)
15 library(ggpubr)
16 library(corrplot)
17 library(reshape2)
18 library(dplyr)
19 library(scales)
20
21 # 1) CARGA Y PREPARACION DE LOS DATOS -----
22 datos_raw <- read_excel("data_clientes.xlsx", sheet = "rep_generacion_cash")
23
24 datos <- datos_raw %>%
25   transmute(
26     especie = factor(cliente, levels = c("B", "A", "A+")),
27     monto_aprobado = 'monto aprobado de cash',
28     mora_promedio = 'mora promedio del cliente (dias)',
29     atraso_maximo = 'atraso maximo del cliente (dias)',
30     atraso_max_3m = 'atraso maximo del cliente ultimos 3 meses (dias)',
31     atraso_actual = 'atraso actual (dias)',
32     n_creditos_vigentes = 'numero de creditos vigentes',
33     deuda_compartamos = 'deuda total en compartamos',
34     n_empresas_sbs = 'numero de empresas en la SBS',
35     deuda_sbs = 'deuda directa en la SBS',
36     ingresos = Ingresos,
37     egresos = egresos,
38     resultado_neto = 'resultado neto'
39   )
40
41 # Imputacion de valores faltantes (ausencia de registro = 0)
```

```

42 datos$atraso_actual[is.na(datos$atraso_actual)] <- 0
43 datos$n_empresas_sbs[is.na(datos$n_empresas_sbs)] <- 0
44 datos$deuda_sbs[is.na(datos$deuda_sbs)] <- 0
45 datos <- na.omit(datos)
46
47 vars_pred <- c("monto_aprobado", "mora_promedio", "atraso_maximo", "atraso_max_3m",
48               "atraso_actual", "n_creditos_vigentes", "deuda_compartamos",
49               "n_empresas_sbs", "deuda_sbs", "ingresos", "egresos", "resultado_netto")
50
51 # Estandarizacion (z-score) para coeficientes comparables
52 datos_z <- datos
53 datos_z[vars_pred] <- scale(datos[vars_pred])
54
55 # 2) EXPLORACION GRAFICA -----
56 plots_hist <- lapply(vars_pred, function(v) {
57   ggplot(datos, aes(x = .data[[v]], fill = especie)) +
58     geom_histogram(position = "identity", alpha = 0.55, bins = 15) +
59     scale_fill_manual(values = c("B"="firebrick", "A"="goldenrod2", "A+"="forestgreen")) +
60     theme_bw(base_size = 9) + theme(legend.position = "bottom")
61 })
62 ggarrange(plotlist = plots_hist, ncol = 3, nrow = 4, common.legend = TRUE)
63
64 corrplot(cor(datos[, vars_pred]), method = "color", type = "upper",
65          addCoef.col = "black", number.cex = 0.6)
66
67 # 3) VERIFICACION DE SUPUESTOS -----
68 datos_tidy <- melt(datos, id.vars = "especie", value.name = "valor",
69                  variable.name = "variable")
70 shapiro_tab <- datos_tidy %>%
71   group_by(especie, variable) %>%
72   summarise(p_value = shapiro.test(valor)$p.value, .groups = "drop")
73
74 box_m_test <- function(data, group) {
75   groups <- split(data, group)
76   n_g <- sapply(groups, nrow); p <- ncol(data); n <- sum(n_g); g <- length(groups)
77   S_list <- lapply(groups, function(d) cov(as.matrix(d)))
78   S_pooled <- Reduce('+', Map(function(S, nj) S*(nj-1), S_list, n_g)) / (n-g)
79   log_det_pooled <- determinant(S_pooled, logarithm = TRUE)$modulus
80   log_det_each <- sapply(S_list, function(S) determinant(S, logarithm = TRUE)$modulus)
81   M <- (n-g)*log_det_pooled - sum((n_g-1)*log_det_each)
82   c1 <- ((sum(1/(n_g-1)) - 1/(n-g)) * (2*p^2+3*p-1)) / (6*(p+1)*(g-1))
83   df <- (g-1)*p*(p+1)/2
84   chi_sq <- M*(1-c1)
85   list(chi_sq = chi_sq, df = df, p_value = pchisq(chi_sq, df, lower.tail = FALSE))
86 }
87 box_result <- box_m_test(datos[, vars_pred], datos$especie)
88
89 # 4) ESTIMACION DEL MODELO LDA (Procedimiento de Fisher) -----
90 modelo_lda <- lda(especie ~ monto_aprobado + mora_promedio + atraso_maximo +
91                  atraso_max_3m + atraso_actual + n_creditos_vigentes +
92                  deuda_compartamos + n_empresas_sbs + deuda_sbs +
93                  ingresos + egresos + resultado_netto,
94                  data = datos_z)
95 print(modelo_lda)
96
97 # 5) EVALUACION DEL MODELO -----
98 predicciones <- predict(modelo_lda, datos_z[, vars_pred])
99 matriz_conf <- table(datos$especie, predicciones$class)
100 training_error <- mean(datos$especie != predicciones$class) * 100
101
102 modelo_lda_cv <- lda(especie ~ monto_aprobado + mora_promedio + atraso_maximo +
103                     atraso_max_3m + atraso_actual + n_creditos_vigentes +
104                     deuda_compartamos + n_empresas_sbs + deuda_sbs +
105                     ingresos + egresos + resultado_netto,
106                     data = datos_z, CV = TRUE)
107 cv_error <- mean(datos$especie != modelo_lda_cv$class) * 100
108
109 # 6) VISUALIZACION DEL ESPACIO DISCRIMINANTE -----
110 lds <- as.data.frame(predicciones$x)
111 lds$especie <- datos$especie

```

```
112 | ggplot(lds, aes(x = LD1, y = LD2, color = especie)) +  
113 |   geom_point(size = 3, alpha = 0.85) +  
114 |   stat_ellipse(type = "norm", level = 0.68) +  
115 |   scale_color_manual(values = c("B"="firebrick", "A"="goldenrod2", "A+"="forestgreen")) +  
116 |   theme_bw(base_size = 13) +  
117 |   labs(title = "Espacio discriminante LDA: LD1 vs LD2")  
118 |
```

Apéndice B

Anexo B: Salida completa del modelo en R

```
1 Call:
2 lda(especie ~ monto_aprobado + mora_promedio + atraso_maximo +
3   atraso_max_3m + atraso_actual + n_creditos_vigentes + deuda_compartamos +
4   n_empresas_sbs + deuda_sbs + ingresos + egresos + resultado_netto,
5   data = datos_z)
6
7 Prior probabilities of groups:
8   B A A+
9 0.2192982 0.5350877 0.2456140
10
11 Coefficients of linear discriminants:
12           LD1 LD2
13 monto_aprobado 0.86216919 -0.438973935
14 mora_promedio 0.02658228 -0.428248187
15 atraso_maximo 0.32052721 0.494686658
16 atraso_max_3m -0.45652369 0.285214110
17 atraso_actual -0.11782640 -0.529882346
18 n_creditos_vigentes 0.15551853 -0.313920811
19 deuda_compartamos 0.13085878 -0.593608440
20 n_empresas_sbs -0.69169179 -0.182326136
21 deuda_sbs -0.61573260 0.374619393
22 ingresos 0.83675062 -0.058699075
23 egresos -0.62362391 -0.268486603
24 resultado_netto -0.57252884 -0.009953206
25
26 Proportion of trace:
27   LD1 LD2
28 0.812 0.188
29
30 MATRIZ DE CONFUSION (training)
31   Clase predicha
32 Clase real B A A+
33   B 3 20 2
34   A 3 51 7
35   A+ 2 9 17
36
37 Training error: 37.72% | Accuracy: 62.28%
38 Error de clasificacion (LOOCV): 62.28%
```