

UNIVERSIDAD NACIONAL DEL ALTIPLANO
FACULTAD DE INGENIERÍA ESTADÍSTICA E INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA ESTADÍSTICA E
INFORMÁTICA

REGRESIÓN LOGÍSTICA MÚLTIPLE

Aplicada a la predicción del resultado académico
(Aprobado / Desaprobado)

Docente: Ing. Eloy Carpio Vargas

Presentado por: Quispe Holguin Alexander

Código: 190179

Curso: Aprendizaje Supervisado

Semestre: VII – 2026-I

Puno – Perú
2026

Contents

Contents	1
1 Introducción	2
2 Metodología	3
2.1 Fuente de datos	3
2.2 Modelo estadístico	3
2.3 Procedimiento	3
3 Resultados	5
3.1 Análisis exploratorio de datos	5
3.2 Estimación del modelo y significancia de los coeficientes	6
3.3 Desempeño predictivo del modelo	10
4 Conclusiones	13
A Apéndice: Código fuente en R	14

Chapter 1

Introducción

La regresión logística es un modelo estadístico de clasificación supervisada que permite estimar la probabilidad de ocurrencia de un evento dicotómico (por ejemplo, aprobar o desaprobar un examen) en función de una o más variables predictoras, ya sean cuantitativas o cualitativas. A diferencia de la regresión lineal, la regresión logística modela la probabilidad mediante la función logística (sigmoide), garantizando que las predicciones se encuentren siempre en el intervalo $[0, 1]$, y estima los parámetros del modelo mediante el método de máxima verosimilitud.

El presente informe desarrolla un modelo de **Regresión Logística Múltiple** aplicado a un conjunto de datos de 500 estudiantes (`student_exam_data_new.csv`), con el objetivo de predecir la probabilidad de que un estudiante apruebe (*Pass*) o desapruebe (*Fail*) un examen, en función de dos variables predictoras: las horas de estudio dedicadas (`study_hours`) y la calificación obtenida en un examen previo (`prev_score`).

El desarrollo del trabajo sigue la metodología propuesta en el curso de Aprendizaje Supervisado, dictado por el Ing. Eloy Carpio Vargas, e incluye las etapas de análisis exploratorio de datos, ajuste del modelo, evaluación de la significancia estadística de los coeficientes, verificación de supuestos (multicolinealidad y bondad de ajuste), validación del poder predictivo mediante matriz de confusión y curva ROC, y validación cruzada de 10 particiones (*10-fold cross-validation*).

Chapter 2

Metodología

2.1 Fuente de datos

Se utilizó el conjunto de datos `student_exam_data_new.csv`, compuesto por 500 observaciones y las siguientes variables:

- **study_hours** (X_1): número de horas de estudio dedicadas por el estudiante (variable cuantitativa continua).
- **prev_score** (X_2): calificación obtenida en un examen previo, en escala de 0 a 100 (variable cuantitativa continua).
- **pass_fail** (Y): variable dependiente binaria, codificada como 0 = Desaprobado (*Fail*) y 1 = Aprobado (*Pass*).

2.2 Modelo estadístico

El modelo de regresión logística múltiple se especifica como:

$$\text{logit}(P) = \ln \left(\frac{P(Y = 1)}{1 - P(Y = 1)} \right) = \beta_0 + \beta_1 \cdot \text{study_hours} + \beta_2 \cdot \text{prev_score} \quad (2.1)$$

de donde la probabilidad de aprobar se recupera mediante la función logística inversa:

$$P(Y = 1 \mid X_1, X_2) = \frac{e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2}}{1 + e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2}} \quad (2.2)$$

Los parámetros $\beta_0, \beta_1, \beta_2$ se estimaron mediante el método de **máxima verosimilitud**, empleando la función `glm()` de R con familia `binomial(link = "logit")`.

2.3 Procedimiento

El análisis se desarrolló en el software R, siguiendo las siguientes etapas:

1. **Carga y preparación de datos**, incluyendo la recodificación de la variable dependiente a formato numérico $\{0, 1\}$ y a factor para fines gráficos.
2. **Análisis exploratorio de datos (EDA)**: diagramas de caja, histogramas superpuestos y diagramas de dispersión por clase, con el fin de identificar visualmente la relación entre predictores y la variable respuesta.
3. **Análisis bivariante**: pruebas t de Student para comparar medias de cada predictor entre los grupos *Pass* y *Fail*, y prueba χ^2 de independencia sobre una categorización de `study_hours`.
4. **Partición de datos** en conjunto de entrenamiento (70%) y prueba (30%), utilizando `createDataPartition()` con semilla fija (`set.seed(123)`) para garantizar reproducibilidad.
5. **Ajuste del modelo nulo y del modelo completo** (`study_hours + prev_score`), y comparación mediante Test de Razón de Verosimilitud (*Likelihood Ratio Test*).
6. **Diagnóstico del modelo**: cálculo del Factor de Inflación de Varianza (VIF) para descartar multicolinealidad, selección *stepwise* por AIC, prueba de bondad de ajuste de Hosmer–Lemeshow y pseudo R^2 de McFadden.
7. **Evaluación predictiva** sobre el conjunto de prueba: matriz de confusión, sensibilidad, especificidad, exactitud, curva ROC y área bajo la curva (AUC).
8. **Validación cruzada de 10 particiones** (*10-fold CV*) para estimar la capacidad de generalización del modelo.
9. **Interpretación de coeficientes** en términos de *odds ratio* (OR) y aplicación del modelo a la predicción de nuevos estudiantes.

Los paquetes de R empleados fueron: `ggplot2`, `ggpubr`, `gridExtra`, `dplyr`, `pROC`, `ROCR`, `car`, `caret`, `ResourceSelection` y `lmtest`.

Chapter 3

Resultados

3.1 Análisis exploratorio de datos




Figure 3.1: Diagramas de caja de `study_hours` y `prev_score` según el resultado (Fail/Pass). Se observa una clara separación de medianas entre ambos grupos: los estudiantes que aprueban presentan una mediana de horas de estudio cercana a 7.4 horas frente a 3.8 horas en los que desaprueban, y una mediana de nota previa de aproximadamente 77 frente a 57 puntos.

La Figura 3.1 evidencia que ambos predictores discriminan razonablemente bien entre las dos clases desde una perspectiva univariada, lo cual anticipa coeficientes significativos en el modelo logístico. No se observan valores atípicos extremos que sugieran errores de captura de datos.




Figure 3.2: Histogramas de densidad superpuestos de `study_hours` y `prev_score`, diferenciados por clase (Fail en rojo, Pass en azul). Se aprecia una zona de solapamiento moderado entre 4 y 6 horas de estudio y entre 55 y 75 puntos de nota previa, correspondiente a la región de mayor incertidumbre de clasificación.




Figure 3.3: Diagrama de dispersión de `study_hours` vs. `prev_score`, coloreado según la clase real. Se distingue visualmente una frontera de separación aproximadamente lineal (diagonal) entre las observaciones *Fail* y *Pass*, lo cual es consistente con el supuesto de linealidad en la escala logit que exige el modelo de regresión logística.

3.2 Estimación del modelo y significancia de los coeficientes

El modelo ajustado sobre el conjunto de entrenamiento arroja la siguiente ecuación logística estimada:

$$\widehat{\text{logit}}(P) \approx \beta_0 + 1.16 \cdot \text{study_hours} + 0.13 \cdot \text{prev_score} \quad (3.1)$$

Ambos coeficientes resultaron **estadísticamente significativos** ($p < 0.001$), con signo positivo, lo que indica que tanto un incremento en las horas de estudio como en la nota del examen previo aumentan la probabilidad de aprobar. El intercepto (β_0) es fuertemente negativo, reflejando que, en ausencia de horas de estudio y con nota previa nula, la probabilidad basal de aprobar es cercana a cero. El Test de Razón de Verosimilitud entre el modelo completo y el modelo nulo resultó significativo ($p < 0.001$), confirmando que la inclusión conjunta de ambos predictores mejora sustancialmente el ajuste respecto al modelo sin covariables. El análisis de Factor de Inflación de Varianza (VIF) mostró valores cercanos a 1 para ambos predictores, descartando problemas relevantes de multicolinealidad. Asimismo, la prueba de Hosmer–Lemeshow no rechazó la hipótesis nula de buen ajuste ($p > 0.05$), y el pseudo R^2 de McFadden obtenido evidencia una mejora considerable respecto al modelo nulo, propia de un modelo con alto poder discriminante.




Figure 3.4: Relación entre el log-odds (logit) estimado y cada predictor, manteniendo el otro en su valor mediano. Ambas relaciones son estrictamente lineales por construcción del modelo. El logit cruza el valor cero (equivalente a $P = 0.5$) alrededor de 7 horas de estudio (con nota previa fija en 68.3) y alrededor de 80 puntos de nota previa (con horas de estudio fijas en 5.6), señalando los puntos de indiferencia entre aprobar y desaprobado para cada variable.




Figure 3.5: *Forest plot* de los *Odds Ratios* (OR) estimados con sus respectivos intervalos de confianza al 95%. La variable `study_hours` presenta un OR aproximado de 3.17 (IC95%: 2.42 – 4.16), y `prev_score` un OR aproximado de 1.14 (IC95% con límite inferior superior a 1). Ambos intervalos se encuentran completamente a la derecha de la línea de referencia $OR = 1$, confirmando la significancia estadística de ambos efectos.

En términos de *odds ratio*, la interpretación práctica de los coeficientes es la siguiente:

- Por cada hora adicional de estudio, manteniendo constante la nota previa, el *odds* (la razón de probabilidades) de aprobar se multiplica aproximadamente por **3.17**, es decir, se incrementa en un 217%.
- Por cada punto adicional en la nota del examen previo, manteniendo constantes las horas de estudio, el *odds* de aprobar se multiplica aproximadamente por **1.14**, es decir, se incrementa en un 14% por punto.

Esto sugiere que, en términos relativos por unidad de medida, las horas de estudio tienen un efecto marginal más pronunciado sobre el *odds* de aprobar que la nota previa, aunque ambas variables son predictores relevantes y complementarios del desempeño académico.




Figure 3.6: Curvas logísticas ajustadas de $P(\text{Pass})$ en función de `study_hours` (izquierda, con `prev_score` fijo en 68.3) y de `prev_score` (derecha, con `study_hours` fijo en 5.6). Ambas curvas presentan la característica forma sigmoide de la regresión logística, con la línea punteada horizontal marcando el umbral de decisión $P = 0.5$.




Figure 3.7: Mapa de probabilidad predicha $P(\text{Pass})$ en el espacio bidimensional de predictores. La región roja (baja probabilidad de aprobar) se ubica en la esquina inferior izquierda y la región azul (alta probabilidad) en la esquina superior derecha. La línea punteada negra representa la frontera de decisión del modelo ($P = 0.5$), la cual resulta aproximadamente lineal, consistente con la naturaleza del modelo logístico con dos predictores.

3.3 Desempeño predictivo del modelo

El modelo fue evaluado sobre el conjunto de prueba (30% de los datos, 150 observaciones), utilizando un umbral de clasificación de $P = 0.5$.




Figure 3.8: Matriz de confusión del modelo sobre el conjunto de prueba. Se clasificaron correctamente 85 casos *Fail* y 44 casos *Pass*, con 10 falsos positivos y 11 falsos negativos, sobre un total de 150 observaciones de prueba.

A partir de la matriz de confusión se derivan los siguientes indicadores de desempeño:

- **Exactitud (Accuracy):** $(85 + 44)/150 = 86.0\%$.
- **Sensibilidad (Recall de la clase Pass):** $44/(44 + 11) = 80.0\%$.
- **Especificidad (Recall de la clase Fail):** $85/(85 + 10) = 89.5\%$.
- **Precisión (Precision de la clase Pass):** $44/(44 + 10) = 81.5\%$.

Estos resultados indican que el modelo tiene un desempeño global muy satisfactorio, con una capacidad ligeramente superior para identificar correctamente a los estudiantes que desaproveban (especificidad de 89.5%) que a quienes aprueban (sensibilidad de 80.0%), lo cual es consistente con la mayor dispersión de horas de estudio observada dentro del grupo *Fail* en los diagramas de caja de la Figura 3.1.




Figure 3.9: Curva ROC (*Receiver Operating Characteristic*) del modelo sobre el conjunto de prueba. El área bajo la curva (AUC) obtenida es de 0.951, muy próxima a 1, lo cual indica una excelente capacidad discriminante del modelo entre las clases *Pass* y *Fail*, muy por encima del umbral de clasificación aleatoria representado por la línea diagonal punteada.

Un valor de AUC de 0.951 se considera, según las escalas de interpretación habituales en la literatura estadística, dentro de la categoría de discriminación *excelente* ($AUC > 0.9$), confirmando que el modelo separa adecuadamente ambas clases en un amplio rango de umbrales de decisión, y no únicamente en el umbral de 0.5 utilizado para el cálculo de la matriz de confusión.




Figure 3.10: Distribución de la probabilidad predicha $P(\text{Pass})$ según la clase real, mediante diagramas de violín con superposición de diagrama de caja. Se observa una fuerte concentración de probabilidades cercanas a 0 para la clase *Fail* y cercanas a 1 para la clase *Pass*, con escasa masa de probabilidad cruzando el umbral de decisión (línea punteada en 0.5), lo cual respalda visualmente la buena calibración y capacidad discriminante del modelo.

Finalmente, la validación cruzada de 10 particiones (*10-fold cross-validation*) confirmó la estabilidad de las métricas de desempeño obtenidas sobre el conjunto de prueba, con un área bajo la curva ROC promedio consistente con el valor de $\text{AUC} = 0.951$ reportado, lo cual descarta un posible sobreajuste del modelo a la partición particular de entrenamiento y prueba utilizada.

Chapter 4

Conclusiones

1. El modelo de regresión logística múltiple ajustado, con predictores `study_hours` y `prev_score`, resultó altamente significativo en su conjunto (Test de Razón de Verosimilitud, $p < 0.001$), y ambos coeficientes individuales fueron estadísticamente significativos ($p < 0.001$), confirmando que tanto las horas de estudio como la nota del examen previo son predictores relevantes del resultado académico (aprobar/desaprobar).
2. La interpretación en términos de *odds ratio* indica que, por cada hora adicional de estudio, el *odds* de aprobar se multiplica por aproximadamente 3.17, mientras que por cada punto adicional en la nota previa se multiplica por aproximadamente 1.14, evidenciando un efecto marginal más fuerte de las horas de estudio.
3. El diagnóstico del modelo no reveló problemas de multicolinealidad (VIF cercano a 1) ni de bondad de ajuste (prueba de Hosmer–Lemeshow no significativa), por lo que el modelo cumple razonablemente los supuestos requeridos para la regresión logística.
4. El modelo mostró un excelente desempeño predictivo sobre el conjunto de prueba, con una exactitud del 86.0%, sensibilidad del 80.0%, especificidad del 89.5% y un área bajo la curva ROC (AUC) de 0.951, resultados que se mantuvieron estables bajo validación cruzada de 10 particiones.
5. El mapa de probabilidad bidimensional evidenció una frontera de decisión aproximadamente lineal entre ambas clases, coherente con la estructura funcional del modelo logístico con dos predictores continuos, lo cual facilita su interpretación práctica como una regla de decisión combinada entre esfuerzo de estudio y desempeño académico previo.
6. En términos aplicados, el modelo constituye una herramienta útil para la identificación temprana de estudiantes en riesgo de desaprobación, permitiendo a instituciones educativas diseñar estrategias de reforzamiento académico dirigidas, particularmente a estudiantes con baja combinación de horas de estudio y nota previa.

Appendix A

Apéndice: Código fuente en R

A continuación se presenta el script completo desarrollado en R para la ejecución del análisis de regresión logística múltiple, incluyendo la carga de datos, el análisis exploratorio, el ajuste del modelo, los diagnósticos, la evaluación predictiva y la generación de las figuras presentadas en este informe.

```
1 #####
2 # REGRESION LOGISTICA MULTIPLE EN R
3 # Dataset: student_exam_data_new.csv
4 # Variable dependiente (Y): Pass/Fail (0 = Desaprobado, 1 = Aprobado)
5 # Variables independientes: Study Hours (X1) + Previous Exam Score (X2)
6 # Basado en: "Regresion logistica multiple" - FINESI-UNA Puno
7 # Autor: Quispe Holguin Alexander - Aprendizaje Supervisado - VII sem. 2026-I
8 #####
9
10 # ---- 0. PAQUETES -----
11 # install.packages(c("ggplot2", "gridExtra", "ggpubr", "dplyr", "reshape2",
12 #                    "pROC", "ROCR", "car", "caret", "ResourceSelection",
13 #                    "lmtest", "ggeffects", "sjPlot"))
14
15 library(ggplot2)
16 library(gridExtra)
17 library(ggpubr)
18 library(dplyr)
19 library(pROC)
20 library(ROCR)
21 library(car)          # vif()
22 library(caret)        # confusionMatrix()
23 library(ResourceSelection) # hoslem.test()
24 library(lmtest)       # lrtest()
25
26 options(scipen = 999)
27
28 # =====
29 # 1. CARGA Y PREPARACION DE DATOS
30 # =====
31 datos <- read.csv("student_exam_data_new.csv", header = TRUE)
32 names(datos) <- c("study_hours", "prev_score", "pass_fail")
33
34 # La variable Y debe ser numerica 0/1 para glm(family=binomial)
35 datos$pass_fail <- as.integer(datos$pass_fail) # 0 = Fail, 1 = Pass
```

```

36 datos$pass_fac <- factor(datos$pass_fail,
37                           labels = c("Fail","Pass")) # factor para graficos
38
39 str(datos)
40 summary(datos)
41
42 cat("\n--- Distribucion de la variable dependiente ---\n")
43 tabla_y <- table(datos$pass_fail)
44 print(tabla_y)
45 cat("Proporcion:\n"); print(prop.table(tabla_y))
46
47 # =====
48 # 2. EXPLORACION GRAFICA
49 # =====
50 # --- 2.1 Boxplots de cada predictor por clase ---
51 p_box1 <- ggplot(datos, aes(x = pass_fac, y = study_hours, fill = pass_fac)) +
52   geom_boxplot(alpha = 0.7, outlier.colour = "red") +
53   scale_fill_manual(values = c("firebrick","steelblue")) +
54   labs(title = "Study Hours por resultado", x = "Resultado", y = "Horas de
55     estudio") +
56   theme_bw() + theme(legend.position = "none")
57
58 p_box2 <- ggplot(datos, aes(x = pass_fac, y = prev_score, fill = pass_fac)) +
59   geom_boxplot(alpha = 0.7, outlier.colour = "red") +
60   scale_fill_manual(values = c("firebrick","steelblue")) +
61   labs(title = "Previous Exam Score por resultado", x = "Resultado", y = "Nota
62     previa") +
63   theme_bw() + theme(legend.position = "none")
64
65 g_box <- ggarrange(p_box1, p_box2, ncol = 2)
66 ggsave("img/01_boxplots.png", g_box, width = 10, height = 5, dpi = 150)
67 print(g_box)
68
69 # --- 2.2 Histogramas superpuestos ---
70 p_h1 <- ggplot(datos, aes(x = study_hours, fill = pass_fac)) +
71   geom_histogram(bins = 30, position = "identity", alpha = 0.5) +
72   scale_fill_manual(values = c("firebrick","steelblue")) +
73   labs(title = "Distribucion Study Hours", x = "Horas", fill = "Resultado") +
74   theme_bw()
75
76 p_h2 <- ggplot(datos, aes(x = prev_score, fill = pass_fac)) +
77   geom_histogram(bins = 30, position = "identity", alpha = 0.5) +
78   scale_fill_manual(values = c("firebrick","steelblue")) +
79   labs(title = "Distribucion Previous Score", x = "Nota previa", fill = "
80     Resultado") +
81   theme_bw()
82
83 g_hist <- ggarrange(p_h1, p_h2, ncol = 2, common.legend = TRUE, legend = "bottom"
84 )
85 ggsave("img/02_histogramas.png", g_hist, width = 10, height = 5, dpi = 150)
86 print(g_hist)
87
88 # --- 2.3 Scatter coloreado ---
89 p_scatter <- ggplot(datos, aes(x = study_hours, y = prev_score, color = pass_fac)
90 ) +
91   geom_point(alpha = 0.55, size = 1.8) +

```



```

87   scale_color_manual(values = c("firebrick","steelblue")) +
88   labs(title = "Study Hours vs Previous Exam Score",
89        x = "Horas de estudio", y = "Nota previa", color = "Resultado") +
90   theme_bw()
91 ggsave("img/03_scatter.png", p_scatter, width = 7, height = 5, dpi = 150)
92 print(p_scatter)
93
94 # =====
95 # 3. ANALISIS BIVARIANTE (asociacion entre cada X y la Y)
96 # =====
97 cat("\n=== Test de medias - Study Hours por grupo ===\n")
98 t.test(study_hours ~ pass_fac, data = datos)
99
100 cat("\n=== Test de medias - Previous Score por grupo ===\n")
101 t.test(prev_score ~ pass_fac, data = datos)
102
103 # =====
104 # 4. CREACION DE VARIABLE CATEGORICA (para ejemplo de dummy)
105 #   Categorizamos study_hours en Bajo / Medio / Alto
106 # =====
107 datos$sh_cat <- cut(datos$study_hours,
108                    breaks = c(-Inf, 3.5, 6.5, Inf),
109                    labels = c("Bajo","Medio","Alto"))
110
111 cat("\n--- Tabla de contingencia: sh_cat vs pass_fail ---\n")
112 print(table(datos$sh_cat, datos$pass_fac))
113
114 # Asociacion chi-cuadrado
115 chisq.test(table(datos$sh_cat, datos$pass_fac))
116
117 # =====
118 # 5. PARTICION TRAIN / TEST (70 / 30)
119 # =====
120 set.seed(123)
121 idx <- createDataPartition(datos$pass_fail, p = 0.70, list = FALSE)
122 train <- datos[idx, ]
123 test <- datos[-idx, ]
124 cat(paste0("\nTrain: ", nrow(train), " obs | Test: ", nrow(test), " obs\n"))
125
126 # =====
127 # 6. MODELO NULO (referencia)
128 # =====
129 modelo_nulo <- glm(pass_fail ~ 1, data = train, family = binomial(link = "logit")
130                  )
131
132 # =====
133 # 7. MODELO COMPLETO: Regresion Logistica Multiple
134 #   Y = Pass/Fail ~ study_hours + prev_score
135 # =====
136 modelo_full <- glm(pass_fail ~ study_hours + prev_score,
137                   data = train, family = binomial(link = "logit"))
138
139 cat("\n===== SUMMARY MODELO COMPLETO =====\n")
140 print(summary(modelo_full))
141
142 # --- Coeficientes e intervalos de confianza ---

```

```

142 cat("\n--- Coeficientes (log-odds) ---\n")
143 print(coef(modelo_full))
144
145 cat("\n--- Odds Ratio (exp(coeficientes)) con IC al 95% ---\n")
146 or_tabla <- exp(cbind(OR = coef(modelo_full), confint(modelo_full)))
147 print(round(or_tabla, 4))
148
149 # =====
150 # 8. PRUEBAS DE BONDAD DE AJUSTE
151 # =====
152
153 # --- 8.1 Test de razon de verosimilitud (LRT): modelo full vs nulo ---
154 cat("\n--- Likelihood Ratio Test: modelo full vs nulo ---\n")
155 lrt <- lrtest(modelo_nulo, modelo_full)
156 print(lrt)
157
158 # --- 8.2 Devianza, AIC, BIC ---
159 cat(paste0("\nDevianza residual : ", round(deviance(modelo_full), 4)))
160 cat(paste0("\nAIC : ", round(AIC(modelo_full), 4)))
161 cat(paste0("\nBIC : ", round(BIC(modelo_full), 4), "\n"))
162
163 # --- 8.3 Pseudo R-cuadrado de McFadden ---
164 pseudo_R2 <- 1 - (logLik(modelo_full) / logLik(modelo_nulo))
165 cat(paste0("\nPseudo R2 McFadden: ", round(as.numeric(pseudo_R2), 4), "\n"))
166
167 # --- 8.4 Test de Hosmer-Lemeshow (bondad de ajuste) ---
168 cat("\n--- Test de Hosmer-Lemeshow ---\n")
169 prob_train <- predict(modelo_full, type = "response")
170 hl_test <- hoslem.test(train$pass_fail, prob_train, g = 10)
171 print(hl_test)
172 # H0: el modelo se ajusta bien => p > 0.05 indica buen ajuste
173
174 # =====
175 # 9. MULTICOLINEALIDAD (VIF)
176 # =====
177 cat("\n--- Factor de Inflacion de Varianza (VIF) ---\n")
178 print(vif(modelo_full))
179 # VIF < 5: sin problemas de multicolinealidad
180
181 # =====
182 # 10. SELECCION DE MODELOS (stepwise forward/backward por AIC)
183 # =====
184 cat("\n=== Seleccion automatica de variables (stepwise por AIC) ===\n")
185 modelo_step <- step(modelo_nulo,
186                     scope = list(lower = modelo_nulo,
187                                   upper = modelo_full),
188                     direction = "forward", trace = 1)
189 print(summary(modelo_step))
190
191 # =====
192 # 11. INTERPRETACION DE LA ECUACION LOGISTICA
193 # =====
194 b0 <- coef(modelo_full)[1]
195 b1 <- coef(modelo_full)[2]
196 b2 <- coef(modelo_full)[3]
197 cat(paste0(

```

```

198   "\n==== ECUACION LOGISTICA ====\n",
199   "logit(P) = ", round(b0,4),
200   " + ", round(b1,4), " * study_hours",
201   " + ", round(b2,4), " * prev_score\n\n",
202   "P(Pass) = exp(logit) / (1 + exp(logit))\n"
203 ))
204 cat("Interpretacion OR:\n")
205 cat(paste0(" - Por cada hora adicional de estudio el odds de aprobar se
      multiplica por ",
206           round(exp(b1),4), "\n"))
207 cat(paste0(" - Por cada punto adicional en nota previa el odds de aprobar se
      multiplica por ",
208           round(exp(b2),4), "\n"))
209
210 # =====
211 # 12. PREDICCIONES SOBRE EL SET DE TEST
212 # =====
213 prob_test <- predict(modelo_full, newdata = test, type = "response")
214 clase_pred <- ifelse(prob_test >= 0.5, 1, 0)
215 clase_pred_f <- factor(clase_pred, levels = c(0,1), labels = c("Fail","Pass"))
216 real_f <- factor(test$pass_fail, levels = c(0,1), labels = c("Fail","Pass"))
217
218 # =====
219 # 13. MATRIZ DE CONFUSION
220 # =====
221 cat("\n=== Matriz de Confusion (umbral = 0.5) ===\n")
222 cm <- confusionMatrix(data = clase_pred_f, reference = real_f, positive = "Pass")
223 print(cm)
224
225 # Visualizacion de la matriz
226 cm_df <- as.data.frame(cm$table)
227 p_cm <- ggplot(cm_df, aes(x = Reference, y = Prediction, fill = Freq)) +
228   geom_tile(color = "white") +
229   geom_text(aes(label = Freq), size = 10, fontface = "bold") +
230   scale_fill_gradient(low = "white", high = "steelblue") +
231   labs(title = "Matriz de Confusion - Regresion Logistica Multiple",
232        x = "Clase Real", y = "Clase Predicha") +
233   theme_minimal(base_size = 13)
234 ggsave("img/04_confusion_matrix.png", p_cm, width = 6, height = 5, dpi = 150)
235 print(p_cm)
236
237 # =====
238 # 14. CURVA ROC Y AUC
239 # =====
240 roc_obj <- roc(test$pass_fail, prob_test)
241 auc_val <- auc(roc_obj)
242 cat(paste0("\nAUC = ", round(auc_val, 4), "\n"))
243
244 # Grafico ROC con ggplot2
245 roc_df <- data.frame(
246   fpr = 1 - roc_obj$specificities,
247   tpr = roc_obj$sensitivities
248 )
249 p_roc <- ggplot(roc_df, aes(x = fpr, y = tpr)) +
250   geom_line(color = "steelblue", size = 1.2) +
251   geom_abline(intercept = 0, slope = 1, linetype = "dashed", color = "gray50") +

```

```

252   annotate("text", x = 0.65, y = 0.15,
253           label = paste0("AUC = ", round(auc_val, 3)),
254           size = 5, color = "steelblue", fontface = "bold") +
255   labs(title = "Curva ROC - Regresión Logística Múltiple",
256        x = "Tasa de Falsos Positivos (1 - Especificidad)",
257        y = "Tasa de Verdaderos Positivos (Sensibilidad)") +
258   theme_bw()
259 ggsave("img/05_roc_curve.png", p_roc, width = 6, height = 5, dpi = 150)
260 print(p_roc)
261
262 # =====
263 # 15. GRAFICAS DEL MODELO LOGISTICO
264 # =====
265
266 # --- 15.1 Probabilidad predicha vs study_hours (manteniendo prev_score en
267 #       mediana) ---
268 med_score <- median(datos$prev_score)
269 grid_sh <- data.frame(
270   study_hours = seq(min(datos$study_hours), max(datos$study_hours), length.out =
271     200),
272   prev_score = med_score
273 )
274 grid_sh$prob <- predict(modelo_full, newdata = grid_sh, type = "response")
275
276 p_curve1 <- ggplot() +
277   geom_jitter(data = datos, aes(x = study_hours, y = pass_fail, color = pass_fac),
278             ,
279             height = 0.03, alpha = 0.35, size = 1.2) +
280   geom_line(data = grid_sh, aes(x = study_hours, y = prob),
281            color = "navy", size = 1.3) +
282   scale_color_manual(values = c("firebrick", "steelblue")) +
283   geom_hline(yintercept = 0.5, linetype = "dashed", color = "gray40") +
284   labs(title = paste0("Curva logística: Study Hours\n(prev_score fijo = ",
285                    round(med_score, 1), ")"),
286        x = "Study Hours", y = "P(Pass)", color = "Resultado") +
287   theme_bw()
288
289 # --- 15.2 Probabilidad predicha vs prev_score (manteniendo study_hours en
290 #       mediana) ---
291 med_sh <- median(datos$study_hours)
292 grid_sc <- data.frame(
293   prev_score = seq(min(datos$prev_score), max(datos$prev_score), length.out =
294     200),
295   study_hours = med_sh
296 )
297 grid_sc$prob <- predict(modelo_full, newdata = grid_sc, type = "response")
298
299 p_curve2 <- ggplot() +
300   geom_jitter(data = datos, aes(x = prev_score, y = pass_fail, color = pass_fac),
301             height = 0.03, alpha = 0.35, size = 1.2) +
302   geom_line(data = grid_sc, aes(x = prev_score, y = prob),
303            color = "firebrick", size = 1.3) +
304   scale_color_manual(values = c("firebrick", "steelblue")) +
305   geom_hline(yintercept = 0.5, linetype = "dashed", color = "gray40") +
306   labs(title = paste0("Curva logística: Previous Score\n(study_hours fijo = ",
307                    round(med_sh, 1), ")"),

```

```

303     x = "Previous Exam Score", y = "P(Pass)", color = "Resultado") +
304     theme_bw()
305
306 g_curves <- ggarrange(p_curve1, p_curve2, ncol = 2,
307                      common.legend = TRUE, legend = "bottom")
308 ggsave("img/06_curvas_logisticas.png", g_curves, width = 11, height = 5, dpi =
309        150)
310 print(g_curves)
311
312 # --- 15.3 Mapa de probabilidad (contorno 2D) ---
313 grid_2d <- expand.grid(
314   study_hours = seq(min(datos$study_hours), max(datos$study_hours), length.out =
315     150),
316   prev_score = seq(min(datos$prev_score), max(datos$prev_score), length.out =
317     150)
318 )
319 grid_2d$prob <- predict(modelo_full, newdata = grid_2d, type = "response")
320
321 p_mapa <- ggplot() +
322   geom_tile(data = grid_2d, aes(x = study_hours, y = prev_score, fill = prob),
323     alpha = 0.85) +
324   geom_contour(data = grid_2d, aes(x = study_hours, y = prev_score, z = prob),
325     breaks = 0.5, color = "black", size = 0.9, linetype = "dashed") +
326   scale_fill_gradient2(low = "firebrick", mid = "white", high = "steelblue",
327     midpoint = 0.5, name = "P(Pass)") +
328   geom_point(data = datos, aes(x = study_hours, y = prev_score,
329     shape = pass_fac, color = pass_fac),
330     size = 1.2, alpha = 0.7) +
331   scale_color_manual(values = c("firebrick", "steelblue")) +
332   scale_shape_manual(values = c(4, 16)) +
333   labs(title = "Mapa de probabilidad P(Pass) - Regresion Logistica Multiple",
334     subtitle = "Linea punteada negra = frontera de decision (P = 0.50)",
335     x = "Study Hours", y = "Previous Exam Score",
336     color = "Resultado", shape = "Resultado") +
337   theme_bw()
338 ggsave("img/07_mapa_probabilidad.png", p_mapa, width = 8, height = 6, dpi = 150)
339 print(p_mapa)
340
341 # --- 15.4 Probabilidades predichas vs reales (calibracion) ---
342 test$prob_pred <- prob_test
343 test$clase_pred <- clase_pred
344
345 p_probs <- ggplot(test, aes(x = factor(pass_fail), y = prob_pred, fill = factor(
346   pass_fail))) +
347   geom_violin(alpha = 0.6, trim = FALSE) +
348   geom_boxplot(width = 0.1, fill = "white", alpha = 0.8) +
349   geom_hline(yintercept = 0.5, linetype = "dashed", color = "gray40") +
350   scale_fill_manual(values = c("firebrick", "steelblue"),
351     labels = c("Fail", "Pass")) +
352   labs(title = "Distribucion de P(Pass) predicha por clase real",
353     x = "Clase real (0 = Fail, 1 = Pass)", y = "P(Pass) predicha",
354     fill = "Clase real") +
355   theme_bw()
356 ggsave("img/08_violines_prob.png", p_probs, width = 6, height = 5, dpi = 150)
357 print(p_probs)
358

```

```

355 # --- 15.5 Grafico de efectos marginales (log-odds vs predictores) ---
356 grid_sh$logit <- predict(modelo_full, newdata = grid_sh, type = "link")
357 grid_sc$logit <- predict(modelo_full, newdata = grid_sc, type = "link")
358
359 p_logit1 <- ggplot(grid_sh, aes(x = study_hours, y = logit)) +
360   geom_line(color = "navy", size = 1.2) +
361   geom_hline(yintercept = 0, linetype = "dashed", color = "gray50") +
362   labs(title = "Log-odds vs Study Hours",
363        x = "Study Hours", y = "logit(P)") + theme_bw()
364
365 p_logit2 <- ggplot(grid_sc, aes(x = prev_score, y = logit)) +
366   geom_line(color = "firebrick", size = 1.2) +
367   geom_hline(yintercept = 0, linetype = "dashed", color = "gray50") +
368   labs(title = "Log-odds vs Previous Score",
369        x = "Previous Exam Score", y = "logit(P)") + theme_bw()
370
371 g_logit <- ggarrange(p_logit1, p_logit2, ncol = 2)
372 ggsave("img/09_logodds.png", g_logit, width = 10, height = 4, dpi = 150)
373 print(g_logit)
374
375 # =====
376 # 16. VALIDACION CRUZADA (10-fold)
377 # =====
378 ctrl <- trainControl(method = "cv", number = 10,
379                      classProbs = TRUE,
380                      summaryFunction = twoClassSummary)
381 datos_cv <- datos
382 datos_cv$pass_fac <- factor(datos_cv$pass_fac, levels = c("Fail", "Pass"))
383
384 set.seed(123)
385 modelo_cv <- train(pass_fac ~ study_hours + prev_score, data = datos_cv,
386                   method = "glm", family = "binomial",
387                   trControl = ctrl, metric = "ROC")
388 print(modelo_cv)
389 cat(paste0("\nAUC promedio (10-fold CV): ", round(modelo_cv$results$ROC, 4), "\n")
390     )
391
392 # =====
393 # 17. PREDICCION DE NUEVOS ESTUDIANTES
394 # =====
395 nuevos <- data.frame(
396   study_hours = c(2, 5, 5, 8, 8),
397   prev_score = c(45, 60, 85, 55, 90)
398 )
399 nuevos$logit <- predict(modelo_full, newdata = nuevos, type = "link")
400 nuevos$P_Pass <- predict(modelo_full, newdata = nuevos, type = "response")
401 nuevos$pred <- ifelse(nuevos$P_Pass >= 0.5, "Pass", "Fail")
402 cat("\n=== Prediccion para nuevos estudiantes ===\n")
403 print(nuevos)
404
405 # =====
406 # 18. TABLA RESUMEN DE RESULTADOS
407 # =====
408 cat("\n\n")
409 cat("===== \n")
410 cat("RESUMEN DEL MODELO DE REGRESION LOGISTICA MULTIPLE\n")

```

```
410 cat("=====\n")
411 cat(paste0("Dataset      : student_exam_data_new.csv (n = ",nrow(datos),")\n"))
412 cat(paste0("Train / Test  : ",nrow(train)," / ",nrow(test)," obs\n"))
413 cat(paste0("Variables     : study_hours + prev_score\n"))
414 cat(paste0("AIC (modelo)   : ", round(AIC(modelo_full),2),"\n"))
415 cat(paste0("Pseudo R2 McFad : ", round(as.numeric(pseudo_R2),4),"\n"))
416 cat(paste0("Accuracy (test) : ", round(cm$overall["Accuracy"]*100,2),"%\n"))
417 cat(paste0("Sensibilidad  : ", round(cm$byClass["Sensitivity"]*100,2),"%\n"))
418 cat(paste0("Especificidad : ", round(cm$byClass["Specificity"]*100,2),"%\n"))
419 cat(paste0("AUC (test)    : ", round(auc_val,4),"\n"))
420 cat("=====\n")
421
422 # Guardar predicciones del test
423 write.csv(test[,c("study_hours","prev_score","pass_fail","prob_pred","clase_pred"
424   )],
425   "resultados_reglog_test.csv", row.names = FALSE)
426
427 cat("\nArchivos PNG guardados en carpeta img/\n")
428 cat("Proceso completado.\n")
```

Listing A.1: Script completo en R: Regresión Logística Múltiple